英文、数字、特殊符号数据集

PaddleOCR

方案:

- 1. 将数据集格式改为训练需求的格式。
- 2. 通过MSER检测选出候选图像文本区域并以二值形式显示(字符旋转、尺寸变化不会影响算法的稳定性),并通过数学形态学将图片中无关区域去掉,尽可能将所有字符区域处于同一连通域,方便字符检测与识别。
- 3. 分别提取候选图像文本区域的HOG特征(去干扰),接着通过字符判断分类器和字符搜索,实现非字符区域的滤除,其中字符判断使用基于N个描述性特征的SVM实现。(可以通过测试图对分类性能进行测试,得到相应准确率)
- 4. 测试上述模型性能((1).使用N幅测试图进行测试,得到相应分类准确率;(2).使用N幅测试图进行字符区域检测定位率测试,得到相应定位准确率)
- 5. 通过垂直投影图像将字符区域字符的分割提取,并分别以json形式记录每个字符对应的坐标。
- 6. 先使用KNN算法对于已有英文、数字、特殊符号数据集进行训练,并测试保证准确率不低于95%。然后对于单个字符图片进行分类识别,将识别结果通过字符坐标依次替换到上述json文件中
- 7. json文件导出csv格式。